

Avance frente ML: modelo predictivo e interpretabilidad

1. Objetivo

El frente ML se usa como complemento del modelo econométrico: busca evaluar si un modelo flexible captura patrones no lineales en el uso de QR y si sus variables relevantes son consistentes con la lectura del MNL.

El modelo busca predecir, para cada viaje individual, si el medio de pago observado corresponde a BIP o QR; en la versión multiclase, distingue además entre QR_RED y QR_OTHER.

Se trabajan dos tareas:

Tarea	Clases
Binaria	BIP vs QR
Multiclase	BIP, QR_OTHER, QR_RED

2. Metodo

La especificación candidata usa la misma decisión territorial del modelo econométrico:

- Variables sociodemográficas e ingreso proxy: medidas en la zona de residencia inferida del usuario.
- Variables operacionales, infraestructura, demanda y macrozona: medidas en el contexto de origen/viaje.
- Modelo final: XGBoost optimizado.
- Entrenamiento final: semanas 2025-W14 y 2025-W15.
- Evaluación fuera de muestra: semana 2025-W17.
- SHAP calculado sobre 199,999 observaciones de W17.

XGBoost usa una pérdida de tipo logit/cross-entropy: log-loss binaria en QR vs BIP y softmax/cross-entropy en multiclase. Esto no lo hace equivalente a un MNL: el MNL estima una utilidad lineal interpretable, mientras que XGBoost aprende funciones no lineales e interacciones.

3. Modelos probados

Se compararon modelos lineales, árboles y boosting. XGBoost quedó como candidato por desempeño y estabilidad.

Familia	Rol
Logit regularizado	Baseline lineal
Random Forest / ExtraTrees	Arboles no boosted
HistGradientBoosting	Boosting base sklearn
LightGBM / CatBoost	Boosting alternativo
XGBoost	Modelo candidato

4. Resultados predictivos en W17

Por desbalance de clases, la accuracy no es la metrica principal: un modelo trivial que predice siempre BIP obtiene alta accuracy, pero no identifica adopcion QR. Por eso se reportan ROC-AUC, PR-AUC macro y log-loss.

Tarea	Modelo can- didato	N train	N test	ROC-AUC W17	PR-AUC macro W17	Log-loss W17
Binaria	XGBoost opti- mizado	633,707	343,382	0.613	0.557	0.440
Multi- clase	XGBoost opti- mizado	633,707	343,382	0.647	0.382	0.506

Lectura: el modelo tiene senal predictiva moderada. No es un clasificador operacional fuerte viaje a viaje, pero si logra ordenar probabilisticamente mejor que un baseline trivial y sirve para estudiar patrones no lineales.

5. Interpretabilidad SHAP

Los graficos muestran que variables empujan la prediccion del modelo. En SHAP, valores positivos aumentan el score de la clase analizada y valores negativos lo reducen.

Figura 1. SHAP binario: QR vs BIP




Figure 1: SHAP binario QR

Lectura: educacion universitaria en la zona de residencia, hora del dia, inmigrantes, discapacidad y variables de friccion del viaje aparecen entre las principales senales para distinguir QR de BIP.

Figura 2. SHAP multiclase: importancia global promedio




Figure 2: SHAP multiclase global

Lectura: la importancia global vuelve a destacar educacion residencial, discapacidad residencial, hora, inmigrantes, proxy de ingreso y macrozona Oriente. Esto es consistente con la idea de que el uso de QR mezcla características residenciales, patrones horarios y contexto operacional.

Figura 3. SHAP multiclase: QR_RED




Figure 3: SHAP multiclase QR_RED

Lectura: QR_RED esta especialmente asociado a educacion residencial, discapacidad residencial, hora, proxy de ingreso y macrozona Oriente. La variable de discapacidad debe interpretarse con cautela: probablemente captura estructura territorial/social correlacionada y no un mecanismo directo simple.

6. Lectura principal

- El frente ML respalda varias senales del MNL, especialmente la importancia de educacion residencial.

- El ML agrega informacion sobre patrones temporales y no lineales, especialmente la hora del viaje.
- La variable de discapacidad aparece de forma relevante tanto en MNL como en SHAP, pero requiere interpretacion cautelosa.
- El proxy de ingreso aparece en SHAP, sobre todo para QR_RED, aunque en el MNL su efecto directo es debil; esto sugiere que puede estar operando en interaccion con educacion, macrozona u otras variables.
- La clasificacion dura de clases raras sigue siendo limitada por el desbalance; el uso mas defendible del ML en esta etapa es probabilistico e interpretativo.

Fuentes de resultados

- Notebook/resumen ML: frente `tesis-project-ml`, especificacion candidata con variables sociodemograficas por residencia.
- Metricas finales: `final_shap_model_metrics_w17.csv`.
- Importancias SHAP: `shap_top_features_by_class.csv` y `shap_global_multiclass_importance.csv`.

Anexo A. Clasificacion dura por clase

La tabla siguiente no es el resultado principal; se incluye solo para mostrar la limitacion del clasificador al convertir probabilidades en clases. Los valores corresponden a la evaluacion W17 de la ronda tuneada comparable de XGBoost.

Tarea	Clase	Precision	Recall	F1	PR-AUC one-vs-rest
Binaria	QR	0.256	0.256	0.256	0.232
Multiclase	QR_RED	0.120	0.116	0.118	0.074
Multiclase	QR_OTHER	0.212	0.209	0.210	0.189

Lectura: el modelo no debe presentarse como una herramienta final de clasificacion individual. Su valor principal es identificar senales y mejorar el ordenamiento probabilistico de adopcion QR.

Anexo B. SHAP multiclase por clase adicional

BIP




Figure 4: SHAP multiclase BIP

QR_OTHER




Figure 5: SHAP multiclasa QR_OTHER

Anexo C. Top variables SHAP por clase

Clase	Top variables
QR binario	Educacion residencial; hora; inmigrantes residenciales; discapacidad residencial; tiempo en vehiculo; espera en transbordo
QR_RED	Educacion residencial; discapacidad residencial; hora; proxy ingreso E-D; macrozona Oriente; asistencia parvularia residencial

Clase	Top variables
QR_OTHER	Educacion residencial; inmigrantes residenciales; hora; espera en transbordo; tiempo en vehiculo; densidad de universidades
BIP	Educacion residencial; hora; discapacidad residencial; inmigrantes residenciales; tiempo en vehiculo; espera en transbordo